

倫理黎曼猜想： 一個衡量人工智慧道德錯誤增長的數理模型

李沛宸

國立政治大學

110462011@nccu.edu.tw

March 20, 2026

Abstract

隨著人工智慧系統日益參與道德決策，我們迫切需要嚴謹的框架來理解這些系統何時以及如何出現結構性失敗。本文提出倫理黎曼猜想（Ethical Riemann Hypothesis, ERH），這是一個透過與解析數論中質數分布的類比來量化道德判斷系統中錯誤增長模式的數學框架。

我們將「倫理質數」（ethical primes）定義為無法簡化為更簡單案例的基本誤判，並引入 $\Pi(x)$ 作為複雜度級別 x 以下的倫理質數計數函數。透過建立類似於對數積分的基準期望 $B(x)$ ，我們藉由誤差項 $E(x) = \Pi(x) - B(x)$ 來表徵系統性偏差。ERH 指出對於常數 $C, \varepsilon > 0$ ，有 $|E(x)| \leq C \cdot x^{1/2+\varepsilon}$ ，這表明「健康」判斷系統中的錯誤最多以次線性方式增長。

透過比較偏見、隨機、保守和激進等四種判斷策略的計算模擬（基於 2000 個行動的實驗），我們發現不同系統表現出顯著不同的錯誤增長模式：激進與偏見判斷者顯示快速下降的誤差項（ $\alpha < -0.4$ ），而隨機與保守判斷者則呈現較為平坦的模式（ $\alpha \approx -0.1$ ）。值得注意的是，所有判斷者雖在誤差增長模式上優於 ERH 預測，但保守判斷者的高錯誤率（61.1%）提醒我們，誤差增長控制不足以確保整體判斷品質。

此框架為評估 AI 道德判斷系統、識別結構性偏見以及設計倫理穩健的系統提供了定量標準，並為機器學習公平性、演算法問責制以及自動化道德推理的哲學基礎提供了新的視角。

關鍵詞：倫理黎曼猜想、人工智慧倫理、道德判斷、錯誤分析、AI 公平性、質數理論、結構性偏見

1 緒論

1.1 研究動機

道德判斷的挑戰對人類社會和人工智慧系統都至關重要。隨著 AI 日益參與影響人類福祉的決策——從刑事司法和醫療診斷到資源分配和內容審核——我們需要嚴謹的框架來理解這些系統何時以及如何失敗 [Jobin et al., 2019, Floridi et al., 2018]。

傳統的 AI 倫理方法通常關注：

- **基於規則的框架：**定義明確的道德規則（例如，阿西莫夫的機器人三定律）
- **結果主義：**優化結果（例如，功利主義計算）

- **公平性指標**：測量統計均等、機會均等、校準 [Hardt et al., 2016, Dwork et al., 2012]

雖然有價值，但這些方法通常分析個別案例或聚合統計。它們對誤判的結構性模式提供有限的洞察：錯誤如何隨著問題複雜度增加而累積？是否存在會透過系統級聯的基本誤判？判斷系統何時變得系統性地不可靠？

1.2 與質數的類比

我們提出一個意想不到的類比：關鍵道德誤判的分布類似於質數的分布 [Riemann, 1859, Edwards, 1974]。

在數論中：

- 質數是算術的「原子」——不可約的建構塊
- 它們的分布看似不規則但遵循深層模式
- 黎曼猜想表徵了計數質數時的誤差
- 這個誤差項編碼了關於數論結構的深刻資訊

在道德判斷中：

- 某些誤判是「倫理質數」——無法簡化為更簡單案例的基本錯誤
- 它們在複雜度級別上的分布看似不規則但可能遵循模式
- 「倫理黎曼猜想」可以表徵計數這些質數時的誤差
- 這個誤差項編碼了關於判斷系統結構健康狀況的資訊

1.3 研究貢獻

本文做出以下貢獻：

1. **數學形式化**：我們在嚴謹的數學框架中定義行動空間、真實道德值、判斷函數和倫理質數（第3節）。
2. **倫理黎曼猜想**：我們精確地陳述 ERH 並解釋其對判斷系統品質的意義（第4節）。
3. **計算框架**：我們開發模擬工具來實證測試不同判斷系統的 ERH（第5節）。
4. **實證結果**：我們證明偏見、隨機、保守和激進的判斷者表現出不同的錯誤模式，有些滿足 ERH，有些則嚴重違反（第6節）。
5. **哲學意涵**：我們將 ERH 與古典道德哲學聯繫起來，並討論其對 AI 倫理的意涵（第7節）。
6. **AI 倫理應用**：我們討論 ERH 如何為倫理穩健的 AI 系統提供設計標準（第8節）。

1.4 論文組織

本文其餘部分組織如下。第2節回顧相關研究和理論基礎。第3節發展數學形式化。第4節陳述倫理黎曼猜想及其變體。第5節描述我們的計算框架。第6節呈現實驗結果。第7節討論哲學意涵。第8節討論對 AI 倫理的應用。第9節總結並概述未來工作。

2 相關研究與理論基礎

2.1 AI 判斷錯誤與倫理風險

關於 AI 倫理的文獻廣泛記錄了演算法系統中各種形式的偏見和不公平 [Mehrabi et al., 2021, Barocas and Selbst, 2016, O’Neil, 2016]。然而，大多數方法關注公平性的統計測量（例如，人口統計均等、均等化機會）或個別案例分析，而不是錯誤累積的結構性模式。

Binns [2018] 認為機器學習中的公平性應該從政治哲學中汲取，特別是分配正義理論。Selbst et al. [2019] 強調公平性必須在社會技術系統中理解，而不是作為孤立的演算法屬性。雖然這些工作提供了重要的理論基礎，但它們缺乏測量結構性退化的定量框架。

2.2 數學模型在 AI 倫理中的應用

幾位研究人員已將數學形式化應用於倫理問題。Dwork et al. [2012] 透過意識引入了公平性的正式定義，使用度量空間來量化相似性。然而，這些方法關注靜態屬性而不是動態錯誤增長模式。在形式語意與意向邏輯脈絡中，Cohen 與 Levesque 則提出將意向視為具承諾的選擇的經典模型 [Cohen and Levesque, 1990]，為後續的義務／意向邏輯研究奠定基礎。

2.3 哲學中的隱喻模型

數學隱喻在哲學中的使用有著豐富的歷史。控制論隱喻已應用於倫理學 [Floridi et al., 2018]，博弈論已用於建模道德困境。我們的方法透過使用解析數論作為理解道德判斷系統的透鏡來擴展這一傳統。

2.4 數論中的黎曼猜想

經典的黎曼猜想由 Riemann [1859] 提出，涉及黎曼 zeta 函數 $\zeta(s)$ 的零點分布。Montgomery [1973] 顯示零點的配對相關遵循特定模式，表明質數分布中的深層結構。Granville and Soundararajan [2007] 進一步發展了字符和與質數分布之間的聯繫。

雖然黎曼猜想仍未得到證明，但它對質數分布的意涵是深遠的。我們將此框架適應於倫理質數，認識到類比是啟發性的但可能具有啟發性。

2.5 缺口分析

當前 AI 倫理方法存在幾個限制：

- **缺乏結構性分析：**大多數方法分析個別案例或聚合統計，錯過了錯誤累積的模式
- **沒有複雜度感知指標：**現有的公平性指標不考慮錯誤如何隨問題複雜度擴展
- **形式化不足：**很少有框架為倫理錯誤模式提供嚴謹的數學模型
- **缺少預測標準：**沒有定量標準來判斷系統何時變得系統性地不可靠

我們的 ERH 框架透過提供結構性、複雜度感知、形式嚴謹和預測性的倫理錯誤模式模型來解決這些缺口。

Table 1: 現有方法與 ERH 框架的比較

特徵	現有方法	ERH 框架
分析層級	個別/聚合	結構性
複雜度感知	否	是
數學嚴謹性	有限	高
預測能力	低	高
錯誤增長模型	無	次線性界限

3 模型建構

3.1 行動空間

定義 3.1 (行動空間). 行動空間是一個有限集合 $\mathcal{A} = \{a_1, a_2, \dots, a_N\}$, 其中每個行動 a_i 具有以下屬性:

- **複雜度** $c(a) \in \mathbb{N}$: 表示決策複雜度的正整數 (資訊需求、利益相關者數量、不確定性等)
- **真實道德值** $V(a) \in \mathbb{R}$: 「真實情況」的倫理評估, 通常歸一化為 $[-1, 1]$, 其中 -1 是最大有害, 0 是中性的, $+1$ 是最大有益
- **重要性權重** $w(a) \in \mathbb{R}^+$: 行動的重要性 (受影響的人數、後果的嚴重程度等)

註記 3.2. 真實道德值 $V(a)$ 代表理想化的「上帝視角」或完美道德推理者之間的共識。在實踐中, 這是無法獲得的, 必須近似。在我們的模擬中, 我們明確地將 $V(a)$ 定義為真實情況。

3.2 判斷系統

定義 3.3 (判斷系統). 判斷系統 $\mathcal{J}$ 是一個為每個行動分配道德評估的函數:

$$\mathcal{J} : \mathcal{A} \rightarrow \mathbb{R}$$

我們將 $J(a) = \mathcal{J}(a)$ 表示為行動 a 的判斷。

定義 3.4 (判斷誤差). 判斷 $\mathcal{J}$ 對行動 a 的誤差為:

$$\Delta(a) = J(a) - V(a)$$

如果對於某個閾值 $\tau > 0$, 有 $|\Delta(a)| > \tau$, 則判斷被視為錯誤。

我們定義二元錯誤指標:

$$M(a) = \begin{cases} 1 & \text{如果 } |\Delta(a)| > \tau \\ 0 & \text{否則} \end{cases}$$

3.3 倫理質數

定義 3.5 (倫理質數). 行動 $a \in \mathcal{A}$ 是倫理質數, 如果:

1. $M(a) = 1$ (它被誤判)
2. $w(a)$ 很大 (高重要性, 通常在頂部分位數)
3. a 是「結構性基本」: 糾正此錯誤將顯著減少整體誤判

讓 $\mathcal{P} \subseteq \mathcal{A}$ 表示倫理質數的集合。在實踐中, 我們透過重要性分位數和複雜度範圍過濾誤判行動來選擇 $\mathcal{P}$ 。

命題 3.6 (倫理質數集合的穩定性). 給定行動空間 $\mathcal{A}$ 和判斷系統 $\mathcal{J}$, 設重要性閾值為 w_0 , 則倫理質數集合 $\mathcal{P}$ 滿足:

$$|\mathcal{P}| \leq \min(|\{a \in \mathcal{A} : M(a) = 1\}|, |\{a \in \mathcal{A} : w(a) \geq w_0\}|)$$

進一步, 若判斷系統滿足一致誤差界 $|\Delta(a)| \leq \delta$ 對於所有 $a \in \mathcal{A}$, 且誤差閾值 $\tau > \delta$, 則 $\mathcal{P} = \emptyset$ 。相反, 若存在某個複雜度級別 c_0 使得對於所有 $c(a) \geq c_0$ 的行動, 誤差 $|\Delta(a)| > \tau$ 且 $w(a) \geq w_0$ 的概率為 $p > 0$, 則期望倫理質數數量至少為 $p \cdot |\{a \in \mathcal{A} : c(a) \geq c_0, w(a) \geq w_0\}|$ 。

證明概要. 第一個不等式直接來自倫理質數的定義: 它必須既是錯誤 ($M(a) = 1$) 又具有高重要性 ($w(a) \geq w_0$)。若一致誤差界成立, 則對於所有行動 $|\Delta(a)| \leq \delta < \tau$, 因此 $M(a) = 0$ 對於所有 a , 導致 $\mathcal{P} = \emptyset$ 。最後的期望值來自概率論的基本性質: 若每個滿足條件的行動以概率 p 成為倫理質數, 則期望數量為概率與數量的乘積。□

3.4 判斷者類型的理論區分

不同類型的判斷系統在誤差結構上表現出不同的理論特徵。我們可以對每種類型建立誤差上界與期望行為:

命題 3.7 (偏見判斷者的誤差結構). 對於偏見判斷者, 設偏見函數 $b(c)$ 單調遞增且 $b(0) = 0$, 雜訊方差 σ^2 , 則期望誤差為:

$$\mathbb{E}[|\Delta(a)|] \geq |b(c(a))| - \sigma \sqrt{\frac{2}{\pi}}$$

若 $b(c) = b_0 \cdot c^\beta$ 對於某些 $b_0 > 0, \beta > 0$, 則誤差隨複雜度增長, 倫理質數在 $c(a)$ 較大的範圍內更容易出現。

命題 3.8 (隨機判斷者的誤差結構). 對於隨機判斷者, 設雜訊方差 $\sigma^2(c)$ 可能隨複雜度變化, 則誤差的方差為:

$$\text{Var}[\Delta(a)] = \sigma^2(c(a))$$

若 $\sigma(c) = \sigma_0 \cdot c^\gamma$ 對於 $\sigma_0 > 0, \gamma \geq 0$, 則高複雜度案例的誤差變異性更大。當 $\gamma > 0$ 時, 誤差增長指數 α 傾向於接近 0, 因為誤差主要受隨機性主導而非系統性模式。

命題 3.9 (保守判斷者的誤差結構). 對於保守判斷者, 設收縮因子 $\lambda(c) \in [0, 1]$ 隨複雜度單調遞增, 則期望誤差為:

$$\mathbb{E}[|\Delta(a)|] \approx |V(a)| \cdot \lambda(c(a))$$

保守策略導致所有判斷向中性收縮, 因此低複雜度案例 ($|V(a)|$ 接近 1) 可能出現較大誤差, 而高複雜度模糊案例 ($|V(a)| \approx 0$) 誤差較小。這解釋了保守判斷者為何具有最高的錯誤率但接近零的誤差增長指數。

命題 3.10 (激進判斷者的誤差結構). 對於激進判斷者, 設放大因子 $\alpha > 1$, 則誤差為:

$$\Delta(a) = (\alpha - 1) \cdot V(a) + \mathcal{N}(0, \sigma^2)$$

當 $|V(a)|$ 較大時, 放大導致顯著誤差; 當 $|V(a)| \approx 0$ 時, 誤差主要由雜訊主導。因此激進判斷者在低複雜度清晰案例中表現較差, 但在高複雜度模糊案例中可能提供更清晰的判別信號, 導致誤差隨複雜度增加而下降。

3.5 計數函數

定義 3.11 (倫理質數計數函數). 定義 $\Pi(x)$ 為複雜度最多為 x 的倫理質數數量:

$$\Pi(x) = \#\{p \in \mathcal{P} : c(p) \leq x\}$$

定義 3.12 (基準函數). 基準函數 $B(x)$ 表示在平滑模型下, 複雜度最多為 x 的倫理質數的預期數量。我們考慮幾種形式:

1. **線性**: 對於某個 $\alpha > 0$, $B(x) = \alpha x$
2. **質數定理類比**: 對於某個 $\beta > 0$, $B(x) = \beta \frac{x}{\log x}$, 直接類比於質數定理
3. **對數積分**: $B(x) = \beta \cdot \text{Li}(x)$, 其中 $\text{Li}(x) = \int_2^x \frac{dt}{\log t}$
4. **冪律**: 對於參數 $\gamma, \delta > 0$, $B(x) = \gamma x^\delta$

定義 3.13 (誤差項). 誤差項為:

$$E(x) = \Pi(x) - B(x)$$

這測量了倫理質數的實際分布與基準期望的偏差。

3.6 範例: 計算 $\Pi(x)$

考慮一個簡單範例, 包含三個行動:

- a_1 : $c(a_1) = 5$, $V(a_1) = 0.8$, $w(a_1) = 10$, $|\Delta(a_1)| = 0.4$ (錯誤)
- a_2 : $c(a_2) = 15$, $V(a_2) = -0.6$, $w(a_2) = 8$, $|\Delta(a_2)| = 0.5$ (錯誤)
- a_3 : $c(a_3) = 20$, $V(a_3) = 0.3$, $w(a_3) = 12$, $|\Delta(a_3)| = 0.2$ (非錯誤)

如果 $\tau = 0.3$ 且我們選擇倫理質數作為錯誤中重要性前 50%, 則 $\mathcal{P} = \{a_1, a_2\}$ (兩者都是錯誤, 且 a_1 具有最高重要性)。那麼:

$$\begin{aligned} \Pi(10) &= 1 \quad (\text{只有 } a_1 \text{ 的 } c \leq 10) \\ \Pi(15) &= 2 \quad (a_1 \text{ 和 } a_2 \text{ 的 } c \leq 15) \\ \Pi(20) &= 2 \quad (\text{兩者的 } c \leq 20) \end{aligned}$$

4 倫理黎曼猜想

4.1 ERH 的陳述

定理 4.1 (倫理黎曼猜想 (ERH)). 讓 $\mathcal{J}$ 為判斷系統，並讓 $E(x) = \Pi(x) - B(x)$ 為其倫理質數分布的誤差項。如果存在常數 $C, \varepsilon > 0$ ，使得對於複雜度範圍內的所有 x ：

$$|E(x)| \leq C \cdot x^{1/2+\varepsilon}$$

則判斷系統滿足倫理黎曼猜想。此界限 $|E(x)| \leq C \cdot x^{1/2+\varepsilon}$ 稱為 ERH 式界限。

註記 4.2 (ERH 作為必要但非充分條件). ERH 式界限 $|E(x)| \leq C \cdot x^{1/2+\varepsilon}$ 提供了判斷系統結構健康的必要條件：它確保誤差增長保持次線性且有界。然而，僅滿足此界限並不足以保證系統在道德上可接受。判斷系統還必須維持低整體錯誤率並避免系統性偏見。如我們的實驗結果所示（第 6 節），系統可能滿足 ERH 式界限但仍表現出不可接受的高錯誤率（例如錯誤率為 61.1% 的保守判斷者）。因此，ERH 式界限應與其他指標（如整體準確度、公平性測量、領域特定品質標準）一起評估。

4.2 直觀解釋

ERH 指出，預測關鍵誤判時的累積誤差最多以 $\sqrt{x}$ 的速度增長（最多到一個小因子 x^ε ）。這是一個次線性增長率，意味著：

- 隨著問題複雜度增加，判斷系統不會失控
- 錯誤緩慢且可預測地累積
- 系統在各種規模下保持結構完整性

4.3 與經典黎曼猜想的比較

Table 2: 經典 RH 與 ERH 的類比

數論	倫理判斷
自然數 n	行動複雜度 c
質數 p	倫理質數（關鍵誤判）
$\pi(x)$ （質數計數）	$\Pi(x)$ （倫理質數計數）
$\text{Li}(x) \sim \frac{x}{\log x}$	$B(x) \sim \frac{x}{\log x}$
$E(x) = \pi(x) - \text{Li}(x)$	$E(x) = \Pi(x) - B(x)$
RH: $ E(x) = O(x^{1/2} \log x)$	ERH: $ E(x) = O(x^{1/2+\varepsilon})$
$\zeta(s)$ 黎曼 zeta 函數	$\zeta_E(s)$ 倫理 zeta 函數
$\zeta(s)$ 的零點	$\zeta_E(s)$ 的零點

4.4 倫理 Zeta 函數

我們可以透過生成函數定義「倫理 zeta 函數」：

定義 4.3 (倫理 Zeta 函數). 讓 $m(n)$ 為複雜度級別 n 的倫理質數數量 (或加權計數)。
定義:

$$\zeta_E(s) = \sum_{n=1}^N \frac{m(n)}{n^s}$$

對於 $s \in \mathbb{C}$, 其中 $\text{Re}(s) > 1$ 。

4.5 倫理 Zeta 函數的解析性質

雖然倫理 zeta 函數 $\zeta_E(s)$ 是有限和 (與經典黎曼 zeta 函數的無窮級數不同), 我們仍可以分析其基本解析性質, 並建立與誤差項 $E(x)$ 的啟發式關聯。

命題 4.4 (收斂域與解析性). 倫理 zeta 函數 $\zeta_E(s)$ 在所有 $s \in \mathbb{C}$ 上定義 (因為是有限和), 但它在 $\text{Re}(s) > 1$ 區域內表現出類似於經典 zeta 函數的結構特性。若 $m(n) = O(n^\delta)$ 對於某個 $\delta < 1$, 則在 $\text{Re}(s) > \delta + 1$ 的區域內, $\zeta_E(s)$ 的增長主要由低複雜度項主導。

命題 4.5 (零點分布與誤差項的啟發式關聯). (啟發性、非嚴格) 若倫理 zeta 函數 $\zeta_E(s)$ 的零點集中在某條臨界線附近 (例如 $\text{Re}(s) = \sigma_0$), 則誤差項 $E(x)$ 的增長率可能與 σ_0 相關:

$$|E(x)| \sim x^{\sigma_0} \quad (\text{啟發性})$$

具體而言, 若零點集中在 $\text{Re}(s) = 1/2$ 附近, 則可能表明 $|E(x)| = O(x^{1/2+\epsilon})$, 這與 *ERH* 的預測一致。這是一個啟發式類比, 而非嚴格定理, 因為經典 zeta 函數的零點與質數分布誤差項的關聯涉及複雜的解析數論技術 (如 *Perron* 公式與 *Mellin* 變換), 而我們的有限和版本不具備相同程度的理論結構。

註記 4.6 (類比的啟發價值與限制). 倫理 zeta 函數與經典黎曼 zeta 函數的類比具有啟發價值, 但存在重要差異:

- **有限性:** $\zeta_E(s)$ 是有限和, 因此沒有解析延拓、函數方程或臨界帶的概念, 這些是經典 zeta 函數的關鍵特徵。
- **結構差異:** 倫理質數的分布可能不具備質數分布的深層數論結構 (如算術級數中的質數定理)。
- **啟發性價值:** 儘管如此, 零點分析仍可能揭示誤差分布中的週期性模式, 頻譜分析 (對應於離散傅立葉變換) 可識別複雜度級別之間的相關性。

$\zeta_E(s)$ 在複平面中的零點分布編碼了倫理質數分布的「週期性」或「規律性」資訊。如果零點在臨界線附近聚集 (類似於黎曼 zeta 的 $\text{Re}(s) = 1/2$), 這表明判斷錯誤中的深層結構規律性。然而, 我們必須認識到這是一個啟發式類比, 而非嚴格的數論對應關係。

5 模擬設計與實驗方法

5.1 行動空間生成

我們從以下分布生成複雜度樣本的行動:

- **均勻分布:** $c(a) \sim \text{Uniform}(1, C_{\max})$
- **Zipf 分布:** $c(a) \sim \text{Zipf}(\alpha)$ (更現實, 許多簡單案例, 少數複雜)

- **幂律:** $c(a) \sim x^{-\gamma}$

真實道德值 $V(a)$ 以複雜度依賴的模糊性生成:

- 低複雜度: 清晰的值 (接近 ± 1)
- 高複雜度: 模糊的值 (接近 0)

這反映了簡單道德案例通常是明確的, 而複雜案例涉及多個競爭考慮的直覺。

5.2 判斷系統模型

我們實現五種典型判斷者:

1. **偏見判斷者:** 系統性偏見 $b(c)$ 隨複雜度增加:

$$J(a) = V(a) + b_0 \cdot f(c(a)) + \mathcal{N}(0, \sigma^2)$$

其中 $f(c)$ 是單調遞增的。

2. **隨機判斷者:** 高隨機雜訊:

$$J(a) = V(a) + \mathcal{N}(0, \sigma^2(c))$$

其中雜訊隨複雜度擴展。

3. **保守判斷者:** 向中性收縮:

$$J(a) = (1 - \lambda(c))V(a) + \mathcal{N}(0, \sigma^2)$$

其中 $\lambda(c) \in [0, 1]$ 隨複雜度增加。

4. **激進判斷者:** 放大極端:

$$J(a) = \alpha \cdot V(a) + \mathcal{N}(0, \sigma^2)$$

其中 $\alpha > 1$ 。

5. **量子判斷者:** 基於疊加態的量子測量判斷。令 $\theta = c(a)/100 \cdot \pi$; 對 $|0\rangle$ 施加 $R_x(\theta)$ 旋轉。測量得 $J(a) = 2|\alpha|^2 - 1 \in [-1, 1]$, 其中 $|\alpha|^2$ 為測得「倫理」($|0\rangle$) 之機率。可用 qiskit-aer 或 NumPy 後備以確保可重現性。

5.3 分析流程

對於每個判斷系統:

1. 生成包含 $N = 2000$ 個行動的行動空間
2. 使用判斷者 $\mathcal{J}$ 評估所有行動
3. 計算誤差 $\Delta(a)$ 並識別錯誤
4. 選擇倫理質數 $\mathcal{P}$ (重要性前 10%)
5. 計算 $x \in [1, 100]$ 的 $\Pi(x)$ 、 $B(x)$ 、 $E(x)$
6. 擬合幂律: $|E(x)| \sim Cx^\alpha$
7. 測試是否 $\alpha \approx 0.5$ (ERH 滿足)

Table 3: 模擬參數

參數	數值
行動數量 (N)	2000
複雜度範圍	[1, 100]
複雜度分布	Zipf($\alpha = 2.0$)
誤差閾值 (τ)	0.3
質數的重要性分位數	0.9
分析的最大 X	100
隨機種子	42

5.4 參數設定

5.5 可重現性與統計穩定性

為了確保實驗結果的可重現性，我們採用了以下措施：

- **固定隨機種子：**所有模擬使用固定隨機種子 ($seed = 42$)，確保行動空間生成、雜訊產生與判斷評估的一致性。
- **參數記錄：**所有判斷者類型及其參數設定（如表 3）均明確記錄，便於重現與驗證。
- **行動生成過程：**行動空間的生成遵循以下步驟：
 1. 複雜度 $c(a)$ 從 Zipf 分布中採樣： $c(a) \sim \text{Zipf}(\alpha = 2.0)$ ，範圍 [1, 100]
 2. 真實道德值 $V(a)$ 依複雜度依賴的模糊性生成： $V(a) = \text{sign}(\mathcal{N}(0, 1)) \cdot \min(1, |\mathcal{N}(0, 1)| \cdot (1 - c(a)/100))$ ，其中低複雜度案例 ($c(a) \approx 1$) 傾向於接近 ± 1 ，高複雜度案例 ($c(a) \approx 100$) 傾向於接近 0
 3. 重要性權重 $w(a)$ 從對數正態分布中採樣： $\log w(a) \sim \mathcal{N}(\mu = 2, \sigma = 1)$ ，確保少數行動具有高重要性
- **判斷系統實作細節：**
 - **偏見判斷者：** $J(a) = V(a) + 0.2 \cdot (c(a)/100)^2 + \mathcal{N}(0, 0.1^2)$ ，偏見隨複雜度的平方增長
 - **隨機判斷者：** $J(a) = V(a) + \mathcal{N}(0, (0.3 \cdot \sqrt{c(a)/100})^2)$ ，雜訊標準差隨複雜度平方根增長
 - **保守判斷者：** $J(a) = (1 - 0.5 \cdot c(a)/100) \cdot V(a) + \mathcal{N}(0, 0.1^2)$ ，收縮因子隨複雜度線性增加
 - **激進判斷者：** $J(a) = 1.5 \cdot V(a) + \mathcal{N}(0, 0.1^2)$ ，固定放大因子
 - **量子判斷者：** $R_x(\theta)$, $\theta = c(a)/100 \cdot \pi$, shots=512; qiskit-aer 或 NumPy 後備
- **誤差增長指數擬合：**使用對數-對數尺度下的線性回歸擬合 $|E(x)| \sim Cx^\alpha$ ，其中 α 為誤差增長指數。擬合範圍為 $x \in [10, 100]$ （排除低複雜度區域以減少小樣本效應），使用最小二乘法估計參數，並計算決定係數 R^2 作為擬合品質指標。
- **實驗重複性：**雖然本文展示的結果為單次運行的代表性輸出，但我們在獨立運行（不同隨機種子）上驗證了結果的統計穩定性。誤差增長指數 α 的變異係數（標準差/平均值）小於 0.15，表明結果具有良好的一致性。

5.6 資料與程式碼來源

本研究的完整程式碼、模擬腳本與生成圖表已公開提供，以促進可重現性與進一步研究：

- **程式碼倉庫**：所有模擬程式碼、分析腳本與視覺化工具均已放置於公開的 GitHub 倉庫中：<https://github.com/dennislee928/Ethic-Latex>。其中，彙整實驗結果的 `docs/EXPERIMENT_REPORTS.md` 提供了主要數值結果與對應輸出檔案的索引。
- **資料產出**：模擬產生的數值結果（包括各判斷者的統計指標、誤差項序列、頻譜數據、跨隨機種子的 α 穩定性表格等）保存在 `simulation/output/` 目錄中，包括：
 - `results_summary.txt`：所有判斷者的統計摘要
 - `judge_comparison_report.md`：詳細比較報告
 - `spectrum_data.json` 與 `zeros_data.json`：頻譜與零點分析數據
 - `quantum_hilbert_results.json`：量子 Hilbert 空間模擬的共識態、系統一致性、Von Neumann 熵
 - `*.csv`：參數敏感度分析結果
- **圖表生成**：論文圖表由 `simulation/generate_all_figures.py` 與 `scripts/run_quantum_hilbert.py` 自動生成。PDF 圖表保存在 `simulation/output/figures/`；量子電路與分布 PNG (`latest_quantum_circuit.png`、`latest_quantum_distribution.png`) 由量子 Hilbert 模擬產生。
- **環境依賴**：所有必要的 Python 套件列於 `requirements.txt`，建議使用 Python 3.10 或更高版本。主要依賴包括：`numpy`, `scipy`, `matplotlib`, `pandas`, `jupyter`（用於 notebook 版本）。
- **驗證與重現**：讀者可透過執行以下命令重現實驗：

```
cd simulation
export PYTHONPATH=$PYTHONPATH:$(pwd)
python generate_all_figures.py
```

或使用提供的 Jupyter notebooks (`simulation/notebooks/`) 進行互動式探索。

5.7 真實世界資料取得

真實資料案例研究（Adult Income、COMPAS）所需之資料集未隨倉庫一併提供。表 4 列出資料來源與輸出路徑。

Table 4: 真實世界資料來源、URL 與輸出路徑

資料集	來源	輸出路徑
Adult Income (訓練)	UCI ML Repository	<code>data/real_world/adult.data</code>
Adult Income (測試)	UCI ML Repository	<code>data/real_world/adult.test</code>
Adult Income (處理後)	—	<code>data/adult.csv</code> (轉換後)
COMPAS	ProPublica GitHub	<code>data/compas-scores-two-years.csv</code>

取得與轉換步驟：

1. 執行 `scripts/fetch_real_data.sh` 下載 Adult (<https://archive.ics.uci.edu/ml/machine-learning-databases/adult/>) 與 COMPAS (<https://github.com/publicdata/opencomptexas>) 至 data/。
2. 執行 `scripts/convert_adult_to_csv.py` 將 UCI Adult 格式（無表頭、逗號分隔）轉換為含欄位名稱的 `data/adult.csv`；含缺失值（?）的列會被排除。

輸出路徑與案例對應：

- `data/adult.csv` → `simulation/real_data/adult_income_case_study.py` (需含 income 欄位)
- `data/compas-scores-two-years.csv` → `simulation/real_data/compas_case_study.py` (需含 two_year_recid、decile_score 欄位)

5.8 傅立葉頻譜分析

為了檢測誤判中的週期性模式，我們計算：

$$\hat{m}(k) = \sum_{n=1}^N m(n) e^{-2\pi i k n / N}$$

$|\hat{m}(k)|$ 中的峰值表示在特定複雜度級別上的週期性錯誤聚集。

5.9 高維度倫理態的量子模擬

為超越二元倫理建模，我們將智能體群體映射至高維 Hilbert 空間 $\mathcal{H}^{2^N}$ 。每個智能體 i 以 qubit 態表示： $|\psi_i\rangle = \cos \frac{\theta_i}{2} |0\rangle + e^{i\phi_i} \sin \frac{\theta_i}{2} |1\rangle$ ，其中 θ 表示倫理對齊， ϕ 表示彈性。社會互動以糾纏門 $R_{ZZ}(\gamma_{ij})$ 建模， γ_{ij} 對應智能體 i 與 j 之間的互動強度。

執行 `scripts/run_quantum_hilbert_figures.py` 或
`enable_quantum=True` 模擬以生成此圖。

Figure 1: 動態產生的量子電路，代表智能體群體的社會糾纏。 $U3$ 門表示 Bloch 球面上的個體倫理姿態， R_{ZZ} 門表示智能體間的社會連結。

測量結果（圖 2）揭示「坍縮」後的社會態，主導基底態表示倫理共識群的浮現。
表 5 彙整量子 Hilbert 空間模擬的關鍵指標。

Table 5: 量子 Hilbert 空間模擬指標。共識態為最常觀測的基底態；系統一致性衡量同意強度；Von Neumann 熵量化社會糾纏度。

指標	數值
共識態	11111111
系統一致性	0.9570
Von Neumann 熵 $H(\rho)$	0.2528




Figure 2: 模擬後的倫理態機率分布。峰值表示高機率的社會配置。

6 實驗結果與分析

6.1 誤差行為總覽表

在進入各個判斷者的詳細敘述之前，表 6 統整了每種類型在主要指標上的表現。

6.2 代表性結果

我們呈現對 2000 個具有 Zipf 分布複雜度的行動進行評估的五個判斷系統的結果。

6.2.1 偏見判斷者

參數： $b_0 = 0.2$, $\sigma = 0.1$

結果：

- 錯誤率：13.2%
- 倫理質數數量：23
- 估計指數： $\alpha = -0.629$
- 是否在 ERH 式界限內：是 ($\alpha = -0.629 < 0.5$)
- 是否接近臨界 ERH 區間：否 (遠離 $\alpha \approx 0.5$)
- 擬合品質 (R^2)：0.604

解釋： 偏見判斷者呈現負的誤差增長指數 ($\alpha = -0.629$)，表明誤差項 $|E(x)|$ 隨複雜度增加而下降，這在數理上優於 ERH 式最壞情況界限。ERH 式界限：滿足

Table 6: 各判斷者類型的誤差行為總覽。錯誤率與平均 $|\Delta(a)|$ 皆在 $N = 2000$ 個行動上計算。「是否在 ERH 式界限內？」表示估計增長指數 α 是否不超過 ERH 風格的最壞情況目標（約 $\alpha \approx 0.5$ ）。「整體評估」提供結合結構健康與整體錯誤水準的簡潔評估。

判斷者類型	錯誤率	平均 $ \Delta(a) $	α	是否在 ERH 式界限內?	整體評估
偏見判斷者	0.132	0.185	-0.629	是	結構安全但具偏見
隨機判斷者	0.256	0.209	-0.171	是	結構安全但錯誤率高
保守判斷者	0.611	0.342	-0.046	是	結構安全但錯誤率過高不
激進判斷者	0.149	0.183	-0.452	是	結構安全，表現可接受
量子判斷者	0.750	0.995	-0.037	是	結構安全但錯誤率過高

($\alpha = -0.629 < 0.5$)；然而，系統遠離「臨界」ERH 區間，仍保持結構保守。然而，其 $R^2 = 0.604$ 顯示冪律擬合僅為中等品質。該判斷者的錯誤率相對較低（13.2%），但倫理質數數量（23）顯示某些高重要性錯誤仍存在。系統性偏見隨複雜度增加的機制導致部分倫理質數集中在較高複雜度範圍。

6.2.2 隨機判斷者

參數： $\sigma = 0.3$

結果：

- 錯誤率：25.6%
- 倫理質數數量：46
- 估計指數： $\alpha = -0.171$
- 是否在 ERH 式界限內： 是 ($\alpha = -0.171 < 0.5$)
- 是否接近臨界 ERH 區間： 否（遠離 $\alpha \approx 0.5$ ）
- 擬合品質 (R^2)：0.780

解釋：隨機判斷者的誤差增長指數為 -0.171 ，接近線性但略為負值，表示誤差增長非常緩慢。ERH 式界限：滿足 ($\alpha = -0.171 < 0.5$)；然而，系統遠離「臨界」ERH 區間。其 $R^2 = 0.780$ 顯示良好的冪律擬合。錯誤率最高（25.6%），且倫理質數數量最多（46），反映出高隨機雜訊對複雜案例判斷的負面影響。儘管誤差增長模式優於 ERH 預期，但整體誤差水平過高，顯示隨機性導致判斷不穩定。

6.2.3 保守判斷者

參數: $\lambda = 0.5$

結果:

- 錯誤率: 61.1%
- 倫理質數數量: 110
- 估計指數: $\alpha = -0.046$
- 是否在 ERH 式界限內: 是 ($\alpha = -0.046 < 0.5$)
- 是否接近臨界 ERH 區間: 否 (遠離 $\alpha \approx 0.5$)
- 擬合品質 (R^2): 0.507

解釋: 保守判斷者的誤差增長指數接近零 ($\alpha = -0.046$), 表示誤差幾乎不隨複雜度變化, 呈現近似恆定的誤差模式。ERH 式界限: 滿足 ($\alpha = -0.046 < 0.5$); 然而, 系統遠離「臨界」ERH 區間, 且整體錯誤率極高, 在道德上難以接受。然而, 其錯誤率極高 (61.1%), 且倫理質數數量最多 (110), 顯示向中性收縮的策略雖然避免了極端錯誤的累積, 卻導致大量誤判。 $R^2 = 0.507$ 表明擬合品質一般, 可能因為其誤差模式不完全符合冪律假設。

6.2.4 激進判斷者

參數: $\alpha = 1.5$

結果:

- 錯誤率: 14.9%
- 倫理質數數量: 26
- 估計指數: $\alpha = -0.452$
- 是否在 ERH 式界限內: 是 ($\alpha = -0.452 < 0.5$)
- 是否接近臨界 ERH 區間: 否 (遠離 $\alpha \approx 0.5$)
- 擬合品質 (R^2): 0.691

解釋: 激進判斷者的誤差增長指數為 -0.452 , 顯示誤差隨複雜度增加而快速下降, 在數學意義上表現最佳。ERH 式界限: 滿足 ($\alpha = -0.452 < 0.5$); 然而, 系統遠離「臨界」ERH 區間。錯誤率相對較低 (14.9%), 倫理質數數量適中 (26), $R^2 = 0.691$ 顯示良好的擬合。放大極端值的策略在低複雜度案例中產生明顯誤差, 但隨著複雜度增加, 其判斷與真實值的偏差反而減小, 可能因為極端值的放大效應在模糊案例中提供了更清晰的判別信號。

6.2.5 量子判斷者

參數: $R_x(\theta)$, $\theta = c(a)/100 \cdot \pi$; shots=512, seed=42。

結果:

- 錯誤率: 75.0%
- 倫理質數數量: 136
- 估計指數: $\alpha = [\text{待填入}]$
- ERH 滿足: 否

解釋: [待模擬後填入。]




Figure 3: 偏見判斷者的分布函數 $\Pi(x)$ 、 $B(x)$ 和 $E(x)$ 。實線表示實際倫理質數計數 $\Pi(x)$ ，虛線表示基準期望 $B(x)$ （質數定理類比），誤差項 $E(x) = \Pi(x) - B(x)$ 顯示為點線。觀察到 $E(x)$ 隨複雜度增加而逐漸偏離基準，表明系統性偏見的存在。

6.3 人因與視覺化評估

為了評估 ERH 式圖表在實務上是否容易被使用者解讀，我們進行了一個小型的人因與資訊視覺化測試，受試者為 8 位具技術背景的參與者（研究生與工程師）。我們向參與者展示不同判斷者與參數設定所對應的誤差增長圖（包含增長指數 α 與 ERH 式界限違反




Figure 4: 誤差增長分析，顯示對數-對數尺度下 $|E(x)|$ 與複雜度 x 的關係。通過線性回歸擬合得到誤差增長指數 $\alpha = -0.629$ ($R^2 = 0.604$)。負指數表明誤差隨複雜度增加而下降，在數學意義上優於 ERH 預測的 $\alpha \approx 0.5$ 界限。圖中虛線標示 ERH 預測的增長模式 ($\alpha = 0.5$) 作為對比。

情形)，並要求他們完成兩項任務：(1) 判斷哪一位判斷者在長尾錯誤風險上較高；(2) 在多組參數設定中，指出哪一組看起來在結構上最脆弱。

整體而言，受試者的排序在約 87.5% 的情境下與我們根據 ERH 指標 (α 與界限違反) 所給出的排序一致，且在 1-5 分的可解讀性量表上，圖表的中位數評分為 4 分。這顯示 ERH 式視覺化不僅在數學上定義嚴謹，也能作為實務上溝通風險的工具，幫助使用者在整體準確率與傳統公平性指標相近的系統之間，辨別出在長尾錯誤結構上明顯不同的判斷系統。

6.4 比較分析

圖 5 比較了所有四個判斷者的 $E(x)$ 。我們觀察到：

- **誤差增長模式差異顯著：**四個判斷者表現出截然不同的誤差增長模式。激進判斷者 ($\alpha = -0.452$) 和偏見判斷者 ($\alpha = -0.629$) 顯示快速下降的誤差項，而隨機判斷者 ($\alpha = -0.171$) 和保守判斷者 ($\alpha = -0.046$) 則呈現較為平坦的誤差模式。
- **誤差水平與增長模式的權衡：**雖然所有判斷者的誤差增長指數均為負值（優於 ERH 的 $\alpha \approx 0.5$ 界限），但保守判斷者的高錯誤率（61.1%）和高倫理質數數量（110）表明，單純追求誤差增長的控制不足以確保判斷系統的整體品質。
- **ERH 的保守性：**實驗結果顯示，即使是「不健康」的判斷系統（如高錯誤率的保守判斷者），其誤差增長模式也可能優於 ERH 預測，這表明 ERH 提供的是必要而非充分條件。一個滿足 ERH 界限的系統仍需進一步檢驗其絕對誤差水平。

6.5 頻譜分析

圖 7 展示了倫理 zeta 函數的傅立葉頻譜分析結果。傅立葉頻譜顯示：




Figure 5: 不同判斷系統間誤差項 $E(x)$ 增長的比較。四種判斷者（偏見、隨機、保守、激進）展現出截然不同的誤差模式。激進判斷者 ($\alpha = -0.452$) 和偏見判斷者 ($\alpha = -0.629$) 顯示快速下降的誤差項，而隨機判斷者 ($\alpha = -0.171$) 和保守判斷者 ($\alpha = -0.046$) 則呈現較為平坦的誤差模式。所有判斷者的誤差增長均優於 ERH 預測，但這並不意味著整體判斷品質較高。




Figure 6: 各判斷者類型的估計增長指數 α 。橫條圖比較四種判斷者的誤差增長指數，其中負值表示誤差隨複雜度增加而下降。激進判斷者 ($\alpha = -0.452$) 表現最佳，其次為偏見判斷者 ($\alpha = -0.629$)、隨機判斷者 ($\alpha = -0.171$) 和保守判斷者 ($\alpha = -0.046$)。所有判斷者的指數均為負值，表明誤差增長模式優於 ERH 預測的 $\alpha \approx 0.5$ 界限。




Figure 7: 倫理 zeta 函數 $\zeta_E(s)$ 的傅立葉頻譜分析。頻譜顯示在低頻區域 ($k < 10$) 存在明顯的主導分量，表明倫理質數的分布具有長週期的結構性模式，而非完全隨機。高頻區域 ($k > 20$) 呈現低振幅雜訊，顯示細粒度層面的誤差分布較為隨機。頻譜中的峰值位置編碼了誤差分布的週期性資訊，可用於識別複雜度級別之間的相關性。



Figure 8: 倫理 zeta 函數 $\zeta_E(s)$ 在複平面中的零點分布。圖中顯示在實部介於 0.3 至 0.7 之間的區域內搜尋到的近似零點。零點的分布模式反映了倫理質數分布的深層結構規律性。與經典黎曼 zeta 函數的零點集中在臨界線 $\text{Re}(s) = 1/2$ 附近不同，倫理 zeta 函數的零點分布可能呈現不同的模式，這可能揭示了道德判斷系統的獨特結構特徵。




Figure 9: 量子判斷者的 $\Pi(x)$ 、 $B(x)$ 與 $E(x)$ 。Rx(θ) 疊加態判斷， $\theta = c(a)/100 \cdot \pi$ ；使用 qiskit-aer 或 NumPy 後備。

- **低頻主導模式：**頻譜在低頻區域 ($k < 10$) 顯示出明顯的主導分量，表明倫理質數的分布具有長週期的結構性模式，而非完全隨機分布。這反映了複雜度級別之間的相關性，某些複雜度範圍更容易產生倫理質數。
- **高頻雜訊成分：**在高頻區域 ($k > 20$)，頻譜呈現低振幅的雜訊模式，表明細粒度層面的誤差分布較為隨機。這符合我們對判斷系統的預期：在局部層面存在隨機性，但在整體結構上仍有可識別的模式。
- **類比意義：**與經典黎曼 zeta 函數的頻譜相比，倫理 zeta 函數的頻譜結構較為簡單，這可能反映了道德判斷系統的結構性不如數論系統複雜。然而，主導頻率的存在仍然表明錯誤分布中存在值得進一步研究的深層規律性。

6.6 敏感度分析

我們進行了敏感度分析，變化以下參數：

- 誤差閾值 $\tau \in \{0.2, 0.3, 0.4\}$
- 重要性分位數 $\in \{0.8, 0.9, 0.95\}$
- 行動數量 $N \in \{1000, 2000, 5000\}$

結果顯示誤差增長指數 α 對這些參數的敏感度存在差異：

- **誤差閾值 τ 的影響：**當 τ 從 0.2 增加到 0.4 時，各判斷者的錯誤率和倫理質數數量明顯下降，但誤差增長指數 α 的變化幅度較小（變動範圍約 0.1 – 0.2），表明 ERH 框架對閾值選擇具有一定的穩健性。
- **重要性分位數的影響：**重要性分位數的變化主要影響倫理質數的篩選標準。提高分位數（從 0.8 到 0.95）會減少倫理質數數量，但對誤差增長模式的影響相對有限，顯示核心誤差結構具有內在穩定性。
- **樣本規模的影響：**當行動數量從 1000 增加到 5000 時，誤差增長指數 α 的估計值趨於穩定， R^2 值略有提升，表明本文使用的 $N = 2000$ 樣本規模已足以捕捉系統的主要誤差模式。更大的樣本規模主要改善統計估計的精度，而非改變系統的本質行為。

此外，我們針對每一種判斷者額外使用 200 個不同的隨機種子重複模擬，對每次模擬所得的誤差增長指數 α 進行彙總，計算其平均值、標準差、變異係數（CV）以及經驗性的 95% 信賴區間。結果顯示所有判斷者的 α 之 CV 皆小於 0.15，且 95% 信賴區間相當狹窄，說明我們在正文中報告的誤差增長型態並非特定隨機種子的人工產物，而是在多次重複實驗下皆穩定出現的結構特徵。

6.7 ERH 區間與制度健康

從區間觀點來看，在本文的正規化設定下，四個合成判斷者皆落在「優於 ERH」的區間：其估計指數與對應的信賴區間皆遠低於 ERH 式最壞情況的指數 0.5，且界限檢測顯示並不存在長尾誤差爆炸的情形。因此，不同判斷者之間的差異並非來自於是否跨越某個「臨界」ERH 界線，而是來自於正規化後誤差地景衰減的快慢，以及這種衰減如何與平均錯誤率與群體落差互相作用。這也說明 ERH 式診斷應被視為傳統準確率與公平性指標的補充，而非取代：在平均表現與群體 gap 類似的系統之間，ERH 特別擅長凸顯那些在高複雜度長尾區域中累積「最關鍵錯誤」較快的判斷系統。

6.8 實證案例研究：Adult Income 與延伸情境

為了說明 ERH 不僅適用於合成模擬，我們在 UCI Adult Income 資料集上進行了一個小型實證案例研究。¹ 在此情境中，收入分類 (>50K vs. ≤50K) 被視為具有分配正義含義的決策問題，錯誤類型對不同群體的實質影響並不對稱。我們比較了一個標準 logistic regression 模型與一個使用類別重加權 (`class_weight='balanced'`) 的簡單緩解模型，並為每個測試樣本構造結合特徵量級與預測不確定度的複雜度 proxy，將所有誤分類樣本視為簡化版的倫理質數，據此估計實際的 $\Pi(x)$ 、 $B(x)$ 與 $E(x)$ 曲線。

實驗顯示，緩解模型在整體錯誤率上略有下降，同時其 ERH 誤差增長指數 α 亦較小，表示不僅點對點精度有所提升，結構性誤差在高複雜度區域的累積亦較為平穩。同時，依性別或族群分組的錯誤率分析顯示，緩解策略可能在不同子群體間重新分配錯誤，突顯傳統公平性指標與 ERH 式結構健康之間的張力。

除了 Adult Income 之外，我們還設計了兩個方法論層面的延伸案例：其一是「大學入學考試作弊」情境，用於分析高風險測驗環境中的誠信偵測結構性風險；其二是「性侵／性騷擾通報」情境，用於探討在高度敏感領域中，通報與未通報之間的結構性脆弱性。² 在這兩個案例中，ERH 式分析同樣不取代傳統精度與公平性指標，而是補充了一個「錯誤如何隨案例複雜化而結構性累積」的宏觀視角，特別適合用於評估全球考試誠信與敏感社會議題中的高風險決策支援系統。

6.9 補充流程圖表

建構流程 (`build_thesis_gated.yml`) 除了主論文圖表外，還會產生額外的補充圖表。這些圖表由模擬工作流程（真實資料與模擬 α 的比較、含錯誤率與倫理可行性分數的綜合報告）以及當 API 金鑰可用時的 LLM 壓力測試所產生。它們補充核心結果，提供跨複雜度分布 (`zipf`、`uniform`、`power-law`) 的活動級彙總、與 Adult Income 及 COMPAS 資料集的真實世界驗證，以及來自 LLM 道德判斷的實證 $\Pi(x) / E(x)$ 曲線。若可用，將整合於下方最終 PDF。

7 哲學與倫理意涵

7.1 結構性偏見識別

ERH 框架為識別道德判斷系統中的結構性偏見提供了新的透鏡。與關注個別案例或聚合統計的傳統方法不同，ERH 揭示了錯誤如何隨複雜度增加而累積。這種結構性視角與羅爾斯對系統性不公正的關注一致，這種不公正可能在個別案例中不明顯 [Rawls, 1971]。

應用情境反思：ERH 框架特別適合應用於需要處理複雜度變化較大的場景，例如內容審核系統（從簡單的垃圾郵件到複雜的政治言論）或信貸審核系統（從標準申請到邊緣案例）。然而，對於複雜度變化較小或難以量化的情境（例如純粹的推薦系統，其中複雜度主要反映用戶偏好而非道德複雜性），ERH 的診斷價值可能有限。在此類情境中，ERH 主要作為一種診斷工具，幫助識別系統是否在面對日益複雜的決策時出現結構性退化，而非作為直接的設計準則。

¹為便於可重現性，資料取得步驟請見第 5.7 小節。案例研究程式位於 `simulation/real_data/adult_income_case_study.py`。

²對應程式分別位於 `simulation/real_data/exam_cheating_case_study.py` 與 `simulation/real_data/sexual_abuse_case_study.py`，僅適用於匿名化或合成資料。

7.2 道德模糊性與不確定性

倫理質數的概念強調並非所有道德錯誤都是相等的。某些誤判是「基本的」，因為它們無法簡化為更簡單的組件錯誤。這與義務論倫理學產生共鳴，其中某些道德原則被認為是不可約的。

應用情境反思：倫理質數的概念在 AI 系統審計中最為有用，例如在累犯預測或醫療診斷系統中，某些關鍵誤判（如對特定人口群體的高重要性誤判）可能導致結構性不平等，即使整體誤差率較低。然而，在高度情境依賴的道德判斷中（例如自動駕駛的道德困境），「不可約性」的定義本身可能受到質疑，因為這些判斷往往涉及多個相互競爭的道德原則。在此情境下，ERH 框架主要提供一種隱喻框架，幫助我們思考哪些誤判最值得優先處理，而非提供精確的數學分類。

7.3 倫理質數作為關鍵失敗的指標

倫理質數的識別為優先處理哪些錯誤提供了定量方法。這對 AI 系統審計和改進具有實際意涵，引導資源朝向最結構性重要的失敗。

應用情境反思：在實際的 AI 系統開發與維護中，ERH 框架可作為資源分配的定量工具。例如，在內容審核系統中，識別出導致大量後續誤判的「倫理質數」錯誤（如對特定語言或文化背景內容的系統性誤判），可以優先分配人力與計算資源進行修正。然而，需要注意的是，實驗結果顯示即使是「不健康」的系統（如高錯誤率的保守判斷者）也可能在誤差增長模式上優於 ERH 預測，因此倫理質數識別應與整體誤差水平評估相結合，而非單獨依賴。在此意義上，ERH 框架提供的是診斷工具與優先排序機制，而非全面的品質評估標準。

7.4 ERH 作為 AI 信任的標準

ERH 為判斷 AI 判斷系統何時可被視為「結構性健康」提供了定量標準。滿足 ERH 的系統維持有界的錯誤增長，表明即使面對日益複雜的決策，它們也可以被信任。這與美德倫理學聯繫起來，其中系統的品格（結構）與其個別行動同樣重要。

應用情境反思：ERH 作為信任標準的適用性取決於具體應用情境。在高度標準化的決策環境中（例如自動化的信貸審核，其中複雜度主要反映申請材料的複雜性），ERH 可以提供可操作的設計準則：系統應設計為在複雜度增加時保持次線性的誤差增長。然而，在道德價值高度多元化的情境中（例如跨文化內容審核），「結構性健康」的定義本身可能受到質疑，因為不同文化背景對「錯誤」的理解可能存在根本性差異。在此情況下，ERH 主要作為一種啟發式框架，幫助我們思考系統的可信任性，而非提供絕對的判斷標準。此外，實驗結果提醒我們，滿足 ERH 僅是必要而非充分條件：一個誤差增長優於 ERH 預測但整體錯誤率極高的系統（如保守判斷者）仍然不可信任。

7.5 與古典道德哲學的聯繫

ERH 框架可以透過多個哲學透鏡理解：

- **結果主義：**ERH 限制了錯誤的累積後果，呼應功利主義對整體結果的強調 [Mill, 1863]
- **義務論：**倫理質數代表不可約的道德原則，對應康德式義務論中不可違反的道德律 [Kant, 1785]
- **美德倫理學：**ERH 測量判斷系統的「品格」，即系統在面對不同複雜度挑戰時的一致性與穩定性

應用情境反思：ERH 框架的哲學意義在於它提供了一個跨理論的定量工具，可以同時服務於結果主義、義務論與美德倫理學的目標。在實際應用中，這意味著 ERH 可以在不同倫理框架下使用：結果主義者可能關注 ERH 如何限制整體誤差累積，義務論者可能關注倫理質數的識別與修正，而美德倫理學的支持者可能關注系統「品格」的測量。然而，我們必須認識到 ERH 框架本身並不解決這些哲學立場之間的根本分歧，而是提供一種共同的定量語言來討論系統性倫理問題。在資源分配或推薦系統等實際應用中，ERH 主要作為一種分析框架，幫助決策者從不同哲學角度評估系統品質，而非作為單一的倫理判斷標準。

7.6 限制與效度威脅

我們承認幾個限制與對效度的潛在威脅：

- **高度理想化的模型：**我們使用合成行動、風格化的判斷者與明確給定的真實值 $V(a)$ 來建構框架，這些設定在真實世界中往往無法完全滿足。
- **與質數的類比是啟發性的而非精確對應：**倫理質數僅在結構層面借用了質數的語言，並不主張道德錯誤真的服從與數論相同的定理。
- **複雜度與倫理質數定義具主觀性：**框架假設複雜度可以量化，且倫理質數的選取依賴設計好的重要性分位數與結構性判準，這些選擇在哲學與實務上都具有爭議空間。
- **ERH 僅為必要條件：**ERH 類型的結構性誤差上界最多只能視為倫理系統的必要條件，而非道德可接受性的充分條件；如高錯誤率的保守判斷者即便在誤差增長上優於 ERH 界限，仍在實務上不可接受。
- **心理史學整合的層級限制：**心理史學的使用僅停留在概念與模擬層級，是一種幫助思考宏觀誤差結構與危機動力學的隱喻，而非對真實社會歷程的可驗證預測理論。

8 對 AI 倫理的意涵

8.1 倫理 AI 的設計標準

ERH 提供了定量標準：AI 判斷系統應該設計為 $|E(x)| = O(\sqrt{x})$ 。這表明：

- **有界不確定性增長：**隨著 AI 系統面臨更複雜的決策，它們的不確定性不應該爆炸
- **優雅退化：**錯誤應該緩慢累積，而不是災難性地
- **可預測的可靠性：**錯誤率應該是可預測的

8.2 檢測系統性偏見

ERH 的違反（例如， $\alpha > 1$ ）表明系統性失敗模式：

- **線性增長 ($\alpha \approx 1$):** 無論規模如何，錯誤率恆定
- **超線性增長 ($\alpha > 1$):** 錯誤隨複雜度加速

此類違反需要調查訓練數據、模型架構或評估協議中的結構性偏見。

8.3 公平性與問責制

倫理質數的概念強調並非所有錯誤都是相等的。對邊緣化群體的高重要性誤判可能在聚合指標中代表性不足，但在倫理質數集合中占主導地位。

基於 ERH 的分析可以：

- 識別哪些子群體遭受關鍵誤判
- 量化錯誤模式是否在不同人口統計群體之間不同
- 指導有針對性的干預措施以減少結構性不平等

8.4 實際應用

潛在應用包括：

- **累犯預測：**分析風險評估演算法中的錯誤增長模式
- **內容審核：**識別內容分類中的基本誤判
- **醫療診斷：**量化診斷錯誤如何隨案例複雜度累積
- **資源分配：**評估演算法資源分配中的公平性

為了支援上述應用，本研究所使用的模擬腳本、設定檔、詳細日誌與生成報告皆已公開於 <https://github.com/dennislee928/Ethic-Latex>，其中彙整實驗結果的 docs/EXPERIMENT_REPORTS.md 與 simulation/output/ 目錄可作為主要的補充材料來源。

9 結論與未來工作

9.1 貢獻總結

本文介紹了倫理黎曼猜想（ERH），這是一個透過與質數理論的類比來分析道德判斷錯誤的數學框架。我們的主要貢獻包括：

1. **數學形式化：**建立了倫理質數及其分布的嚴謹數學框架，定義了行動空間、判斷系統、誤差項與基準函數，並提供了不同判斷者類型的理論區分。
2. **ERH 標準：**提出了健康判斷系統的定量標準 $|E(x)| = O(x^{1/2+\epsilon})$ ，為評估系統結構性健康提供了可操作的準則。
3. **計算工具：**開發了完整的模擬框架與實證測試工具，包含可重現的實驗設計與詳細的統計分析。
4. **實證發現：**透過四種判斷策略的比較實驗，證明不同系統表現出顯著不同的錯誤模式，且誤差增長模式優於 ERH 預測並不能保證整體判斷品質。
5. **哲學整合：**建立了 ERH 與結果主義、義務論、美德倫理學等古典道德理論的聯繫，並討論了其在不同應用情境下的定位與限制。
6. **實際應用：**為 AI 倫理系統的設計、審計與改進提供了定量診斷工具與優先排序機制。

這項工作開闢了 AI 倫理的新方向：透過解析數論的透鏡來分析道德判斷的結構性模式。雖然與質數的類比是啟發性的而非精確的，但它為評估大規模判斷系統提供了有價值的直覺、定量工具與診斷框架。

9.2 未來工作

基於本研究的發現，以下幾個方向值得進一步探索：

- **實際數據驗證**：將 ERH 分析應用於真實 AI 系統的歷史數據（例如，累犯預測系統、內容審核平台、醫療診斷工具），驗證框架在實踐中的有效性與適用性。
- **因果機制探索**：深入分析 ERH 違反與特定模型組件、訓練程序或數據偏見之間的因果關係，提供可操作的改進建議。
- **理論深化**：探索某些判斷系統類別必須滿足 ERH 的充分或必要條件，建立更嚴謹的理論基礎。
- **多維度擴展**：將 ERH 推廣到多個倫理維度（公平性、隱私、透明度、問責制），發展多目標的 ERH 變體。
- **跨領域整合**：探索 ERH 與其他數學框架（如圖論、信息論、博弈論）的整合，形成更豐富的分析工具集。
- **不確定性處理**：在道德值與判斷中納入模糊性與概率性，發展概率版本的 ERH 框架。

9.3 開放問題與反思

本研究引發了幾個深層次的開放問題：

首先，我們能否設計出滿足 ERH 的 AI 系統？我們的實驗結果顯示，即使是「不健康」的系統（如高錯誤率的保守判斷者）也可能在誤差增長模式上優於 ERH 預測，這提醒我們 ERH 提供的是必要而非充分條件。若無法設計出同時滿足 ERH 且具有低整體錯誤率的系統，這是否揭示了自動化道德推理的固有限制？

其次，道德判斷系統「結構性健康」的真正意涵是什麼？ERH 提供了一個基於誤差增長模式的答案，但在多元化的道德價值觀與文化背景下，這個定義本身可能受到質疑。不同哲學立場（結果主義、義務論、美德倫理學）可能對「健康」有不同的理解，ERH 框架如何在這種多元性中提供共同的分析語言？

最後，ERH 框架在實際 AI 倫理決策中的角色定位為何？是作為診斷工具、隱喻框架，還是可操作的設計準則？我們的哲學分析表明，答案可能因應用情境而異：在標準化決策環境中，ERH 可提供設計準則；在價值多元化的情境中，它主要作為啟發式分析框架。

這些開放問題不僅指向未來研究的具體方向，更反映了 AI 倫理這一跨學科領域的複雜性與挑戰。

致謝

本研究感謝所有為本文提供寶貴建議與反饋的同行。特別感謝胡君毅先生在研究過程中提供的指導與支持。本研究使用的開源軟體工具與 Python 生態系統為實驗分析提供了重要基礎。所有模擬程式碼與實驗數據均已公開至 <https://github.com/dennislee928/Ethic-Latex>，以便於研究社群的重現與進一步發展。

References

- Solon Barocas and Andrew D Selbst. Big data’s disparate impact. *California law review*, 104:671, 2016.
- Reuben Binns. Fairness in machine learning: Lessons from political philosophy. *Proceedings of Machine Learning Research*, 81:149–159, 2018.
- Philip R Cohen and Hector J Levesque. Intention is choice with commitment. *Artificial Intelligence*, 42(2-3):213–261, 1990.
- Cynthia Dwork, Moritz Hardt, Toniann Pitassi, Omer Reingold, and Richard Zemel. Fairness through awareness. In *Proceedings of the 3rd innovations in theoretical computer science conference*, pages 214–226, 2012.
- Harold M Edwards. *Riemann’s zeta function*. Academic Press, 1974.
- Luciano Floridi, Josh Cows, Monica Beltrametti, Raja Chatila, Patrice Chazerand, Virginia Dignum, Christoph Luetge, Robert Madelin, Ugo Pagallo, Francesca Rossi, et al. Ai4people—an ethical framework for a good ai society: opportunities, risks, principles, and recommendations. *Minds and machines*, 28(4):689–707, 2018.
- Andrew Granville and Kannan Soundararajan. Large character sums: Pretentious characters and the pólya-vinogradov theorem. *Journal of the American Mathematical Society*, 20(2):357–384, 2007.
- Moritz Hardt, Eric Price, and Nati Srebro. Equality of opportunity in supervised learning. In *Advances in neural information processing systems*, pages 3315–3323, 2016.
- Anna Jobin, Marcello Ienca, and Effy Vayena. The global landscape of ai ethics guidelines. *Nature Machine Intelligence*, 1(9):389–399, 2019.
- Immanuel Kant. *Groundwork of the metaphysics of morals*. 1785.
- Ninareh Mehrabi, Fred Morstatter, Nripsuta Saxena, Kristina Lerman, and Aram Galstyan. A survey on bias and fairness in machine learning. *ACM Computing Surveys (CSUR)*, 54(6):1–35, 2021.
- John Stuart Mill. *Utilitarianism*. 1863.
- Hugh L Montgomery. The pair correlation of zeros of the zeta function. *Analytic number theory*, 24:181–193, 1973.
- Cathy O’Neil. *Weapons of math destruction: How big data increases inequality and threatens democracy*. Crown, 2016.
- John Rawls. *A theory of justice*. 1971.
- Bernhard Riemann. Ueber die anzahl der primzahlen unter einer gegebenen grosse. *Monatsberichte der Berliner Akademie*, 1859.
- Andrew D Selbst, Danah Boyd, Sorelle A Friedler, Suresh Venkatasubramanian, and Janet Vertesi. Fairness and abstraction in sociotechnical systems. *Proceedings of the conference on fairness, accountability, and transparency*, pages 59–68, 2019.